Tokenization des langues sous-représentées :
le cas du wolof et la Méthode A d'extension de Qwen

Les grands modèles apprennent surtout sur des langues dominantes. Pour le wolof, la tokenization devient un point de rupture : des mots fréquents sont découpés en fragments arbitraires, ce qui dilue le sens grammatical et dégrade l'apprentissage.

Exemple précis de mot mal segmenté. Pour *dégguma* ("je n'ai pas compris"), le tokenizer Qwen produit ici le découpage `dé | ggu | ma` (3 tokens). Ce découpage perd l'unité morphologique complète et complique la capture de la négation. Même effet pour *jàngalekat* (enseignant) ou *xam-xam* (savoir), souvent sur-fragmentés.

Conséquences observables. (i) plus de tokens par phrase ; (ii) faible couverture "single-token" ; (iii) perplexité plus élevée ; (iv) fine-tuning instable avec peu de données.

Méthode A (à tester en premier). On *conserve le tokenizer Qwen* et on l'*étend* pour le wolof :

1. partir du corpus wolof et mesurer la fragmentation produite par Qwen ;
2. détecter les mots fréquents trop fragmentés (patch ciblé) ;
3. ajouter ces unités comme nouveaux tokens, sans supprimer le vocabulaire existant ;
4. initialiser leurs embeddings, puis lancer QLoRA.

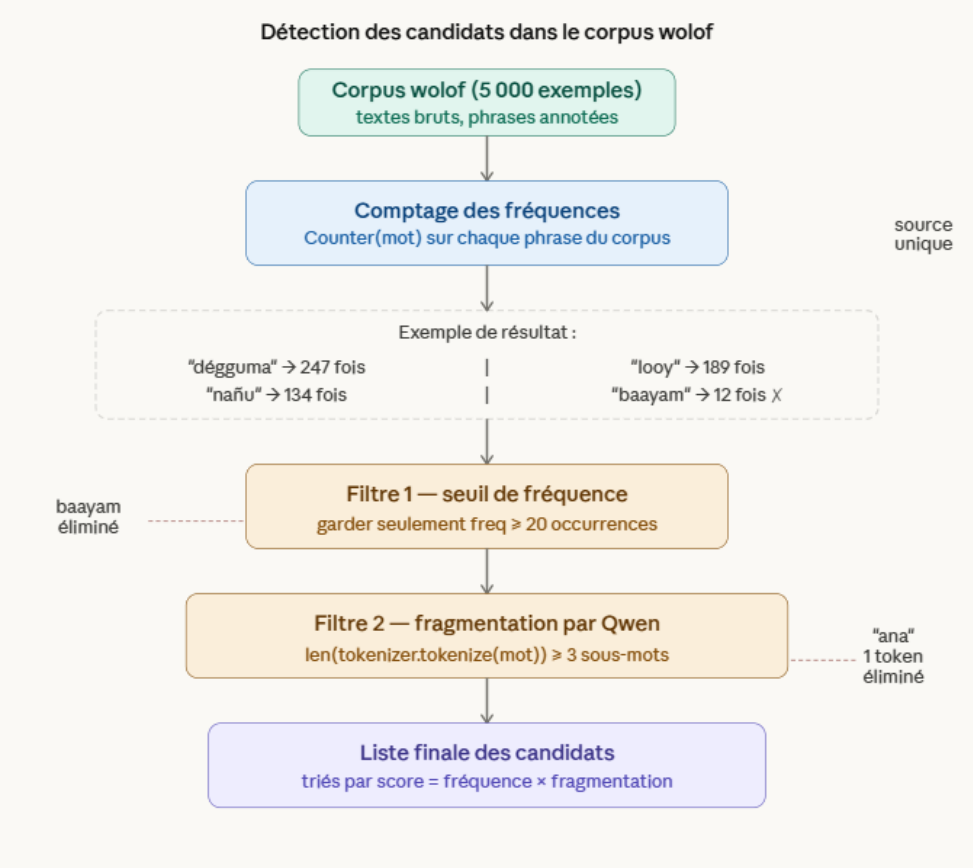

Architecture expérimentale (schéma).

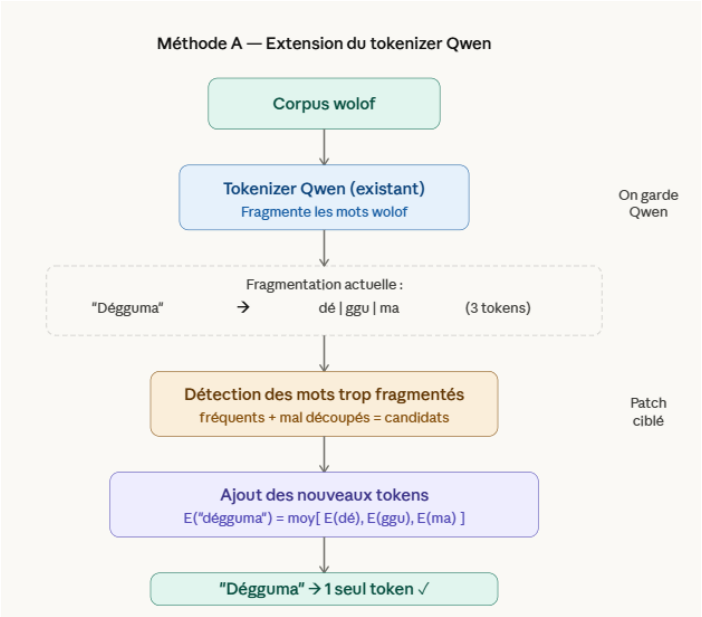

Cette approche est non destructive : la compatibilité d'origine est conservée.

Initialisation des embeddings : moyenne et TF-IDF uniquement. Soit un nouveau token wolof w décomposé par l'ancien tokenizer en sous-tokens $(s_1, \ldots, s_n)$, avec embeddings préexistants $(\mathbf{e}_{s_1}, \ldots, \mathbf{e}_{s_n})$.

Baseline 1 – moyenne simple :

$$\mathbf{e}_w^{\text{mean}} = \frac{1}{n} \sum_{i=1}^{n} \mathbf{e}_{s_i}.$$

Baseline 2 – moyenne pondérée TF-IDF :

$$\mathbf{e}_w^{\text{tfidf}} = \frac{\sum_{i=1}^{n} \alpha_i \, \mathbf{e}_{s_i}}{\sum_{i=1}^{n} \alpha_i}, \quad \alpha_i = \text{tf}(s_i, w) \cdot \log \frac{N}{\text{df}(s_i) + 1}.$$

Ici, les sous-unités discriminantes reçoivent plus de poids.

En résumé, la Méthode A cible les mots ratés par la tokenization. En restaurant des unités wolof entières et en initialisant leurs embeddings par moyenne (simple ou TF-IDF), on donne à QLoRA un point de départ cohérent sous contrainte de données.